گزارش پروژه پایگاه داده پیشرفته

استاد درس: دكتر امين غيبي

نام و نام خانوادگی: حسین نجاتی جوارمی

شماره دانشجویی: 9412057

Contents

3	مقدمه:
3	
3	
3PostgreSQL	
5	
7	
7	
10	
10	. ۔ منابع مط

مقدمه:

در این گزارش ما ابتدا دو سیستم پردازش آنلاین OLAP و OLAP را با هم مقایسه می کرده سپس تعدادی از ابزارهای مورد استفاده در این دو محیط را با هم مقایسه می کرده و نتایج آن را برای هر سیستم اعلام می شود.

تمام کد های نوشته شده در طی انجام این پروژه در گیت هاب قرار گرفته و تمامی افراد حق دسترسی و استفاده از نتایج آن را دارند.

:OITP vs OIAP

:OLAP

- 1. بيشتر خواندن
- 2. کوئری های بزرگ و پیچیده
 - 3. حجم داده زیاد
- 4. زمان زیادی صرف پردازش کوئری می شود
 - 5. ساختار دیتابیس معمولا نرمال نیست

:OLTP

- 1. بیشتر نوشتن و بروز رسانی
- کوئری های کوچک و ساده
 - می تواند خیلی کم باشد
 - 4. نسبتا كمتر است
- 5. معمولا نرمال هستند(3NF)

:OLTP

:PostgreSQL .1

در این قسمت ابتدا دیتابیس و جدول ها را ساختیم و با کمک دستور زیر داده ها را از روی فایل خوانده و به داخل دیتابیس ریختیم.

Copy table_name from file_addres.file_name.tbl (format csv, delimiter '|')

نکته: این دستور به صورت مستقیم پاسخگوی نیاز ما نبود و ما ابتدا باید به تمام جداول یک ستون موقتی اضافه می کردیم و پس از ذخیره کردن داده برروی دیتابیس، آن ستون ها را پاک می کردیم. دلیل این کار وجود علامت ' | ' در آخر تمامی رکورد ها بود.

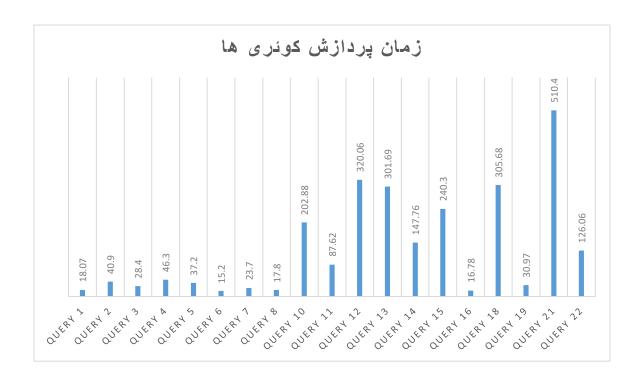
نکته: انجام عمل ذخیره سازی داده برروی دیتابیس زمان بر می باشد و با توجه به شلوغی سرور بین 6 تا 14 ساعت ممکن است طول بکشد.

نکته: حجم داده های ذخیره شده برروی دیتابیس بیشتر از داده ها خام می باشد و دلیل آن هم تغییرات اعمال شده در هنگام ذخیره سازی و ایندکس های ساخته شده می باشد.

در مرحله بعدی کوئری های بنچمارک TPC-H دانلود کرده و آن ها را با مقادیر مجاز کامل کردیم. به دلیل زمان بر بودن اجرای این کوئری ها ما از نرم افزار screen استفاده کردیم تا در صورت قطعی اینترنت یا هر دلیل دیگری اجرای کوئری متوقف نشود.

نکته: برای این که روند تصمیم گیری و اجرا کوئری ها را در دیتابیس ببینیم به اول تمامی کوئری ها دستور explain analyze اضافه شد. روند اجرای کوئری ها در گیت هاب موجود می باشد.

نکته: زمان پردازش کوئری های شماره 9، 17 و 20 بیش از 10 ساعت شد، به همین دلیل اجرای این کوئری ها به صورت دستی متوقف شد.



نکته: تمامی زمان های اعلام شده در جدول بالا به دقیقه می باشد.

نکته: مقادیر جدول بالا، زمان های پردازش می باشد و با زمان واقعی اجرای کوئری ها بسیار متفاوت می باشد و یکی از مهم ترین دلایل این تفاوت دیسک مورد استفاده می باشد.

نکته: در اجرای این کوئری ها مقدار رم و سی پی یو استفاده شده ناچیز می باشد و هزینه اصلی خواندن و نوشتن برروی دیسک می باشد.

Spark .2

در این قسمت ابتدا فایل ها از روی هارد خوانده شده و پس ازانجام تغییرات لازم در فرمت parquet داخل HDFS ذخیره شدند. پس از آن فایل در فرمت parquet خوانده شده و در فرمت های orc و avro داخل HDFS ذخیره شدند. تمامی کد های تبدیل فرمت و جابجایی داده داخل گیت ها قرار گرفته اند.

نکته: هنگام تبدیل داده خام به فرمت parquet ما باید ساختار جداول را مشخص کنیم اما در مراحل بعدی نیازی به این کار نیست.

نکته: حجم داده در هنگام ذخیره سازی در فرمت های orc ،parquet و avro به دلیل فشرده سازی داده ها کاهش پیدا می کند.

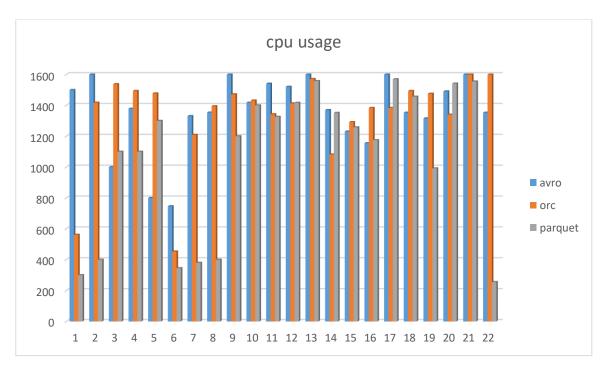
نکته: در هنگام استفاده از فرمت orc باید از تنظیم زیر استفاده کنید:

sqlContext.setConf('spark.sql.orc.iml', 'native')

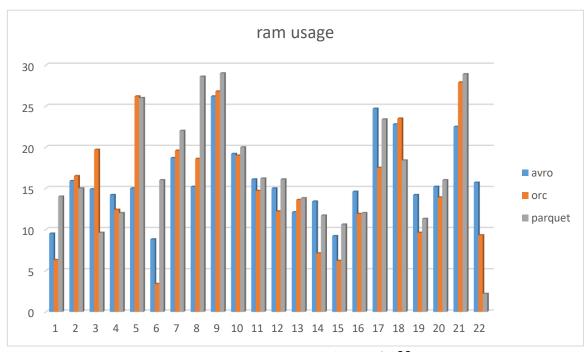
نکته: در هنگام استفاده از فرمت avro باید دو کتابخانه به فایل های jar اسپارک اضافه کنید. این کتابخانه ها در قسمت jar_files داخل گیت هاب قرار گرفته اند.

نکته: کد ها به زبان پایتون نوشته شده اند و از pyspark استفاده شده است.

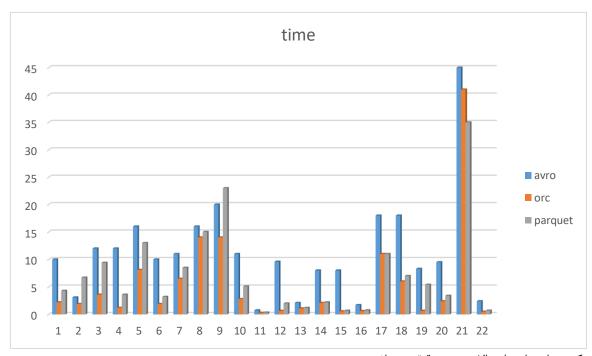
نکته: تمامی کوئری جداگانه اجرا شدند و برای هر کوئری یک سشن جداگانه ساخته شد. دلیل این کار کاهش مراحل اجرای کوئری ها و عدم وابستگی و تاثیر کوئری ها برروی یک دیگر می باشد. در طی انجام گزارش مشاهده شد که اگر بعد از اتمام کوئری ها، سشن ها بسته نشود و کوئری بعدی بر روی هم سشن اجرا شود، حجم زیادی داده از اجرای قبلی برای روی رم کش شده است و سرعت اجرای کوئری جدید کاهش پیدا می کند.



نكته: ميزان مصرف سي پي يو براساس استفاده از تمام 16 هسته موجود مي باشد.



نکته: بر روی اسپارک محدودیت سقف 30 گیگابایت رم گذاشته شده بود.



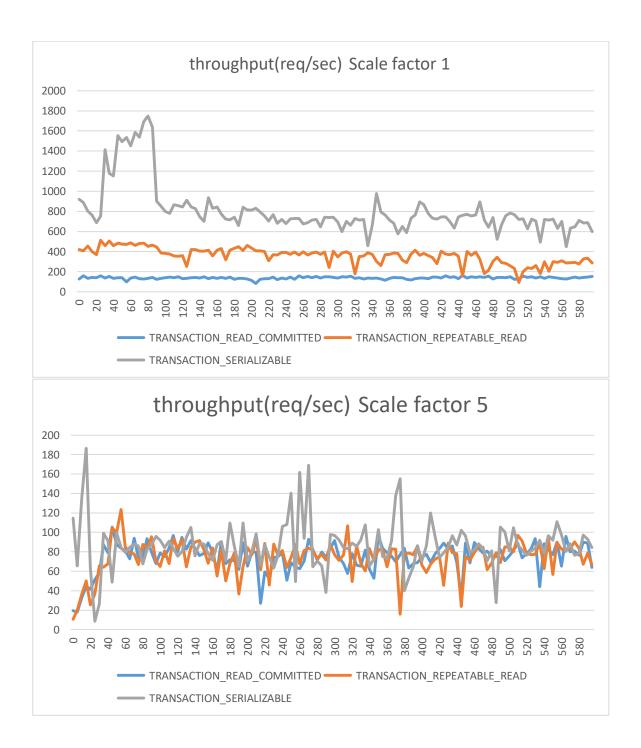
نكته: تمام زمان هاى بالا برحسب دقيقه مى باشند.

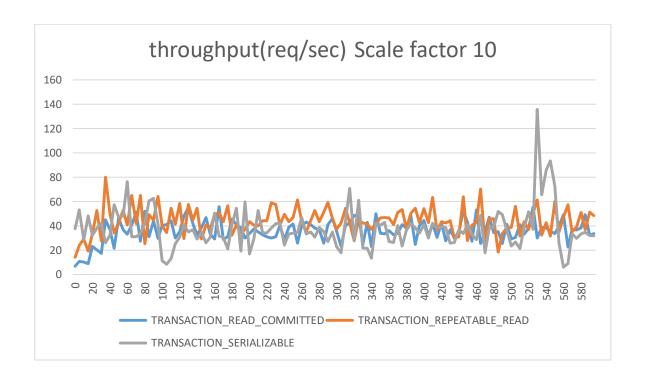
نکته: مقادیر بالا کل زمان اجرا می باشد و با زمان پردازش متفاوت است.

:OLAP

:PostgreSQL .1

در این قسمت با استفاده از ابزار OLTPBenchmark ابتدا به دیتابیس متصل می شویم و با توجه به مقدار ضریب بزرگنمایی داده های مورد آزمایش را می سازیم. در این قسمت ما از ضریب بزرگنمایی 1، 5 و 10 استفاده کردیم.هر چه مقدار ضریب بزرگنمایی، ما بزرگنمایی ما بیشتر باشد، حجم داده ما بیشتر می شود. درنتیجه سرعت ما کاهش میابد. علاوه بر مقدار ضریب بزرگنمایی، ما از سه حالت کنترل همزمانی که دیتابیس پستگره پشتیبانی می کند هم استفاده کردیم و نتایج حاصل به صورت زیر بود.





تمامی فایل های کانفیگ و نتایج حاصل در گیت هاب موجود می باشد.

نکته: در این جا هم مشاهده شد که به دلیل سرعت کم هارد دیسک، میزان کمی سی پی یو و رم استفاده شد.

نکته: با کاهش ضریب بزرگنمایی دیتابیس، تعداد deadlock ها بیشتر می شود.

نکته: برای استفاده از این ابزار حتما باید از جاوا 7 یا 8 نصب کرد.

کامند های مورد استفاده در این قسمت به صورت زیر می باشند:

./oltpbenchmarkn-b tpcc -c config_address -create=true -load=true

./oltpbenchmarkn-b tpcc -c config_address -execute=true -s time_preiod -o output_file_address

CockroachDB .2

در این قسمت هم از ابزار OLTPBenchmark استفاده می کنیم که توسط Robert S Lee برای دیتابیس در این قسمت هم از ابزار کرده است.این ابزار را می توانید با دستور زیر دانلود و نصب کنید:

git clone https://github.com/robert-s-lee/oltpbench.git --branch cockroachdb --single-branch oltpbenchmark; cd oltpbenchmark; ant

متاسفانه سرعت cockroachdb به شدت پایین بود و حتی بعد از گذشت یک روز نتوانست داده مورد نیاز برای تست را تولید کنند. زمان وارد کردن داده برحسب ثانیه برابر 0.15 الی 0.3 بود.

فایل های کانفیگ این نرم افزار در گیب هاب قرار گرفته اند.

کامند های مورد استفاده در این قسمت به صورت زیر می باشند:

./oltpbenchmarkn-b tpcc -c config_address -create=true -load=true

 $./oltpbenchmarkn-b\ tpcc-c\ config_address-execute=true-s\ time_preiod-o\ output_file_address$

منابع مطالعاتي:

- world wide web .1
- docker in action کتاب .2
 - 3. داکیومنت های اسپارک
- 4. دوره آموزشی Taming Big Data with Apache Spark and Python Hands On!
 - 5. دوره آنلاین آموزش لینوکس توسط مهندس جادی
 - 6. منابع سایت https://developer.ibm.com/tutorials/l-lpic1-map.
 - 7. كتاب learning Apache Flink